算法理论+实战之EM聚类

编者荐语：

理论到处有，实践最重要！

以下文章来源于AI蜗牛车 ，作者Miracle8070

AI蜗牛车

作者是南京985AI硕士，CSDN博客专家，研究方向主要是时空序列预测和时间序列数据挖掘，获国家奖学金，校十佳大学生，省优秀毕业生，阿里天池时空序列比赛rank3。公众号致力于技术专栏化，主要包括ML、DL、NLP、CV、个人思考总结等

1. 写在前面

如果想从事数据挖掘或者机器学习的工作，掌握常用的机器学习算法是非常有必要的，常见的机器学习算法：

- 监督学习算法：逻辑回归，线性回归，决策树，朴素贝叶斯，K近邻，支持向量机，集成算法Adaboost等
- 无监督算法：**聚类**，降维，关联规则, PageRank等

为了详细的理解这些原理，曾经看过西瓜书，统计学习方法，机器学习实战等书，也听过一些机器学习的课程，但总感觉话语里比较深奥，读起来没有耐心，并且**理论到处有，而实战最重要**， 所以在这里想用最浅显易懂的语言写一个**白话机器学习算法理论+实战系列**。

个人认为，理解算法背后的idea和使用，要比看懂它的数学推导更加重要。idea会让你有一个直观的感受，从而明白算法的合理性，数学推导只是将这种合理性用更加严谨的语言表达出来而已，打个比方，一个梨很甜，用数学的语言可以表述为糖分含量90%，但只有亲自咬一口，你才能真正感觉到这个梨有多甜，也才能真正理解数学上的90%的糖分究竟是怎么样的。如果这些机器学习算法是个梨，本文的首要目的就是先带领大家咬一口。另外还有下面几个目的：

- 检验自己对算法的理解程度，对算法理论做一个小总结
- 能开心的学习这些算法的核心思想， 找到学习这些算法的兴趣，为深入的学习这些算法打一个基础。
- 每一节课的理论都会放一个实战案例，能够真正的做到学以致用，既可以锻炼编程能力，又可以加深算法理论的把握程度。
- 也想把之前所有的笔记和参考放在一块，方便以后查看时的方便。

学习算法的过程，获得的不应该只有算法理论，还应该有乐趣和解决实际问题的能力！

今天是白话机器学习算法理论+实战的第九篇之EM聚类。听到这个名字，就知道这是一个无监督学习算法了，如果使用基于最大似然估计的模型，模型中存在隐变量的时候，就要用到EM算法去做估计。所以这个算法就是含有隐变量的概率模型参数的极大似然估计法，可能我说的这些话你还听不太懂，什么隐变量，什么极大似然乱七八糟的？没事，通过今天的学习，就能够快速的掌握EM算法的工作原理，还能理解极大似然，还能最后通过调用工具实现EM算法并完成一个王者荣耀英雄人物的聚类（玩游戏的时候，是不是会遇到对手抢了你擅长的英雄的情况啊， 那你该如何选一个和这个英雄整体实力差不多的呢？）。哈哈 ，是不是迫不及待了啊？ 我们开始吧。

大纲如下：

- 从一个生活场景引出EM算法的核心思想（分菜均匀，你该如何划分？）
- 白话EM算法的工作原理，并举例子说明（抛硬币都玩过吧）
- 看看EM聚类（和KMeans有何不同？）
- EM算法实战 - 对王者荣耀的英雄角色进行聚类（实行聚类之后，我们就可以找到可以互相替换的英雄，也就不怕你的对手选择了你擅长的英雄了）

OK, let's go!

2. EM算法，还是先从分菜开始吧！

提起EM算法（英文叫做Expectation Maximization，最大期望算法），你可能是第一次听说过， 但是你知道吗？ 你在生活中可能不止一次用过这个思想了吧， 正所谓我之前常说的**算法来源于生活**。啥？不信？ 那我们看看下面这个场景：

假设，你炒了一份菜，我想要你把它平均分到两个碟子里，该怎么分？
你一听平均分？总不能拿个称来称一称，计算出一半的分量进行平分吧，如果你真这样做，那不得不承认你是个天才，不用学机器学习了。 反正我感觉大部分人的方法是这样做的：

先分一部分到碟子 A 中，然后再把剩余的分到碟子 B 中，再来观察碟子 A 和 B 里的菜是否一样多，哪个多就匀一些到少的那个碟子里，然后再观察碟子 A 和 B

> 里的是否一样多……
> 整个过程一直重复下去，直到份量不发生变化为止。
>
> ”

你是采用的哪种方法呢？ 如果是后者，那么恭喜你，你已经初步认识了EM算法，并且和它打交道不止一次了。下面的知识对你来说已经洒洒水了。轻松愉快的往下走吧。

在这个例子中你能看到三个主要的步骤：初始化参数，观察预期和重新估计。首先是先给每个碟子初始化一些菜量，然后再观察预期，这两个步骤实际上就是**期望步骤（Expectation）简称E步**。如果结果存在偏差就需要重新估计参数，这个就是**最大化步骤（Maximization）简称M步**。这两个步骤加起来也就是 EM 算法的过程。

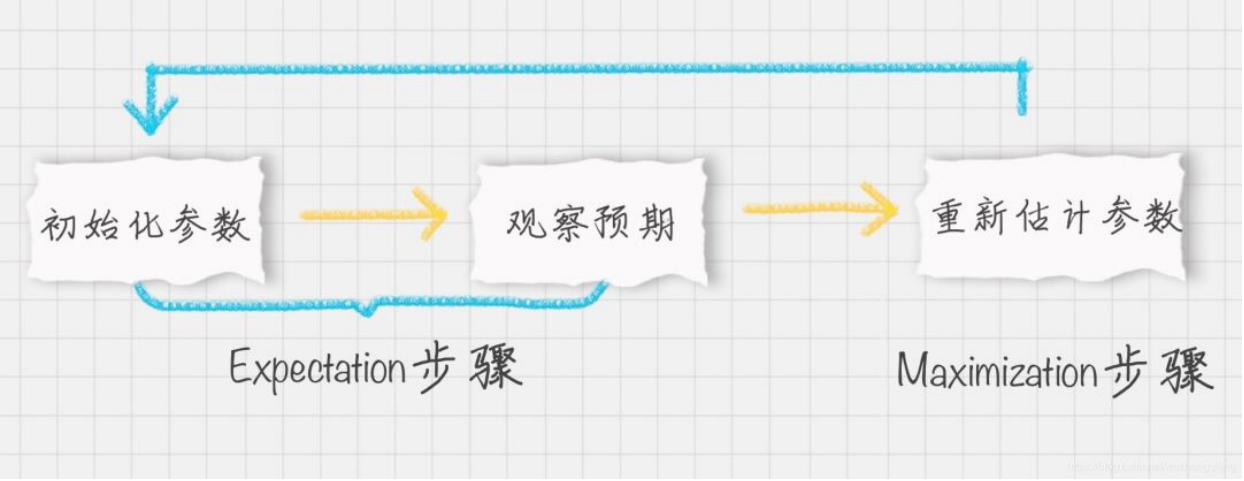

哈哈，是不是豁然开朗了啊，趁着这个时候，看看EM算法的具体工作原理吧。

3. EM算法的工作原理

说到 EM 算法，我们需要先来看一个概念“最大似然”，英文是 Maximum Likelihood，Likelihood 代表可能性，所以最大似然也就是最大可能性的意思。

什么是最大似然呢?

> 举个例子，有一男一女两个同学，现在要对他俩进行身高的比较，谁会更高呢？根据我们的经验，相同年龄下男性的平均身高比女性的高一些，所以男同学高的可能性会很大。这里运用的就是最大似然的概念。

”

那还有一个问题：最大似然估计是什么呢？

它指的就是一件事情已经发生了，然后反推更有可能是什么因素造成的。还是用一男一女比较身高为例，假设有一个人比另一个人高，反推他可能是男性。最大似然估计是一种通过已知结果，估计参数的方法。

”

上面说的这些是啥？EM 算法到底是什么？它和最大似然估计又有什么关系呢？（你这三连问，我有点不知所措）
其实，EM 算法是一种求解最大似然估计的方法，通过观测样本，来找出样本的模型参数。

再回过来看下开头我给你举的分菜的这个例子，实际上最终我们想要的是碟子 A 和碟子 B 中菜的份量，你可以把它们理解为想要求得的模型参数。然后我们通过 EM 算法中的 E 步来进行观察，然后通过 M 步来进行调整 A 和 B 的参数，最后让碟子 A 和碟子 B 的参数不再发生变化为止。

”

然后，你恍然大悟，哦，原理EM算法就这么简单啊，哈哈，不要太高估自己了， 实际我们遇到的问题，比分菜复杂的多。不行，那再看看我给你举的下面这个例子：
抛硬币大家都玩过吧，假设我们有 A 和 B 两枚硬币，我们做了 5 组实验，每组实验投掷 10 次，每次只能只有A或者B一枚硬币。那么我们统计出现每组实验正面的次

数，实验结果如下：

实验	正面次数
1	5
2	7
3	8
4	9
5	4

我想问你，你知道，A硬币和B硬币各自正面朝上的概率吗？

怎么样？蒙了吧， 你说这咋求，每一组实验，我都不知道用的是A或者B抛的。我怎么算？ 那么好，我假设把这个表再给你完善一下：

实验	投掷的硬币	正面次数
1	A	5
2	B	7
3	B	8
4	B	9
5	A	4

这你能告诉我答案了吧？你说：这还不简单， 我们不就可以直接求了，令A正面朝上的概率是θA, B正面朝上的概率是θB，然后：

$$\theta_A = \frac{5+4}{10+10} = 0.45 \ , \ \theta_B = \frac{7+8+9}{10+10+10} = 0.8$$

哈哈， 漂亮！你知道吗？一开始我提到这样一句话：

> ★
>
> 如果使用基于最大似然估计的模型，模型中存在隐变量的时候，就要用到EM算法去做估计
>
> ”

这里的第二列，就是隐含的数据，而A和B就是隐变量。实际中我们是不知道这一列的，就是开始给你的只有实验组数和正面的次数， 那么你该怎么办呢？

也就是说，我们如果不知道每一组扔的是A还是B，那么我们就无法去估计θA和θB，而如果想知道每一组扔的是A还是B，我们就必须先知道A和B正面朝上的概率θA和θB，然后利用极大似然的思想，根据每一组实验正面朝上的次数去估计出这一轮究竟用的A还是B。 有点绕哈！ 你会发现这是一个鸡生蛋蛋生鸡的问题，无法求解！
那么说了半天，应该怎么办呢？ 这里就采用了EM算法的思想。

> 我先随机初始化一个θA和θB， 有了这两个参数，我们就能按照极大似然估计出每一组用的是A还是B，然后基于每一组用的是A还是B，我们又能按照极大似然反过来计算出θA和θB，然后又能去估计新的用的是A还是B，然后又能计算新的θA和θB，这样一轮轮的下去， 当计算出的新的θA和θB与我们前一轮θA和θB一样的时候，说明这个θA和θB有可能就是真实的值了。**这个就是EM初级版**。
>
> ”

好了，根据我上面说的，我们看看怎么实行吧。

下面我们就用上面我说的思想，来做一下这个题目：

1. 初始化参数。

假设抛掷硬币A和B的正面概率（随机指定） θA=0.5　θB=0.9

2. 计算期望值。（这个过程实际上通过假设的参数来估计未知参数，即“每次投掷的是哪枚硬币”）

假设实验1抛掷的是硬币A，那么正面次数为5的概率

$$C_{10}^{5} * 0.5^{5} * 0.5^{5} = 0.24609375$$

假设实验1抛掷的是硬币B，那么正面次数为5的概率

$$C_{10}^{5} * 0.9^{5} * 0.1^{5} = 0.014880348$$

所以实验1抛掷的很有可能是硬币A。

然后实验2-实验5我们都用上面的方法，基于θA和θB，根据正面次数，可以推理出每一轮实验用的是A还是B　最后我们得出这五次实验用的硬币分别是 {A, A, B, B, A}

画出图来感受一下：

实验	抛掷的硬币	正面次数
1	A	5
2	A	7
3	B	8
4	B	9
5	A	4

3. 通过有了这个隐藏值之后，我们就可以完善初始化的参数θA和θB

θA = (5+7+4) / 30 = 0.533333　　θB = (8+9) / 20 = 0.85

然后一直重复第二步和第三步，直到参数不再发生变化。

这里有两个问题需要解答一下：

1. 新估计出的θA和θB一定会更接近真实的θA和θB？答案是：没错，一定会更接近真实的θA和θB，数学可以证明，但这超出了本文的主题，请参阅其他书籍或文章。（这就类似你均匀分菜，总会有分好的那一个点吧）
2. 迭代一定会收敛到真实的θA和θB吗？答案是：不一定，取决于θA和θB的初始化值，一般是会的。

其实，上面介绍的这个只是一个初始的版本，为什么这么说呢？因为我们上面第一次计算概率的时候，我们算出：

假设实验1抛掷的是硬币A， 那么正面次数为5的概率

$$C_{10}^{5} * 0.5^{5} * 0.5^{5} = 0.24609375$$

假设实验1抛掷的是硬币B， 那么正面次数为5的概率

$$C_{10}^{5} * 0.9^{5} * 0.1^{5} = 0.014880348$$

这时候我们直接取得第一次用硬币A(下面几组实验同理)。

你没有发现，这样做决定太硬，太绝对了吗？ 虽然B出现正面次数为5的概率比A的小，但是也不是0啊，就是也有可能出现啊。这时候我们应该考虑进这种可能的情况，那么这时候，第一轮实验用的A的概率就是: 0.246 / (0.246 + 0.015) = 0.9425；用B的概率就是1-0.9425 = 0.0575。

相比于前面的方法，我们按照最大似然概率，直接将第1轮估计为用的硬币A，此时的我们更加谨慎，我们只说，有0.9425的概率是硬币A，有0.0575的概率是硬币B，不再是非此即彼。这样我们在估计θA和θB时，就可以用上每一轮实验的数据，而不是某几轮实验的数据，显然这样会更好一些。

这一步，我们实际上估计的是用A或者B的一个概率分布，这步就称作**E步**。

这样，每一轮实验，我们会求出这样一个表来，分别有A和B的概率：

实验	用A的概率	用B的概率
1	0.9425	0.0575
2		
3		
4		
5		

然后，我们在结合着统计结果，

按照最大似然概率的法则重新估计新的θA和θB：

以硬币A为例， 第一轮的正面次数为5相当于 5次正面，5次反面

- 0.9425 * 5 = 4.7125(这是正面)
- 0.9425 * 5 = 4.7125（这是反面）

那么对于硬币A来说， 可以把五轮的表格画成下面的形式：

轮数	正面	反面
1	0.42	0.28
2	1.22	1.83
3	0.94	3.76
4	0.42	0.28
5	1.22	1.83
总计	4.22	7.98

这样， 新的thetaA = 4.22 / (4.22+7.98)=0.35 这样，改变了硬币A和B的估计方法之后，会发现，新估计的thetaA会更加接近真实的值，因为我们使用了每一轮的数据，而不是某几轮的数据。

PS：上面这个表我只是为了说明意思，截取过来的一个图，真实数据并不是这样的数据，看第一轮也能看出来，真实数据是我上面计算的那个，按照那个计算方法，计算出每一轮的硬币A的时候正面和反面的数据，硬币B的正面和方面的数据，然后求新的θA和θB会更加准确一些。

”

这步中，我们根据E步求出了硬币A和B在每一轮实验中的一个概率分布，依据最大似然法则结合所有的数据去估计新的θ1和θ2， 被称作**M步**。

这个就是进阶版的EM算法。

说到这，EM算法的工作原理可算是介绍完了， 你明白了吗?

简单的总结下上面的步骤:

> 你能看出 EM 算法中的 E 步骤就是通过旧的参数来计算隐藏变量。然后在 M 步骤中，通过得到的隐藏变量的结果来重新估计参数。直到参数不再发生变化，得到我们想要的结果。

”

下面，我们看看EM算法聚类的原理，前面介绍过KMeans聚类，同是聚类，有什么区别?

4. EM聚类的工作原理

EM算法一般用于聚类，也就是无监督模型里面，因为无监督学习没有标签（即y值），EM算法可以先给无监督学习估计一个隐状态（即标签），有了标签，算法模型就可以转换成有监督学习，这时就可以用极大似然估计法求解出模型最优参数。其中估计隐状态流程应为EM算法的E步，后面用极大似然估计为M步。

相比于 K-Means 算法，EM 聚类更加灵活，比如下面这两种情况，K-Means 会得到下面的聚类结果。

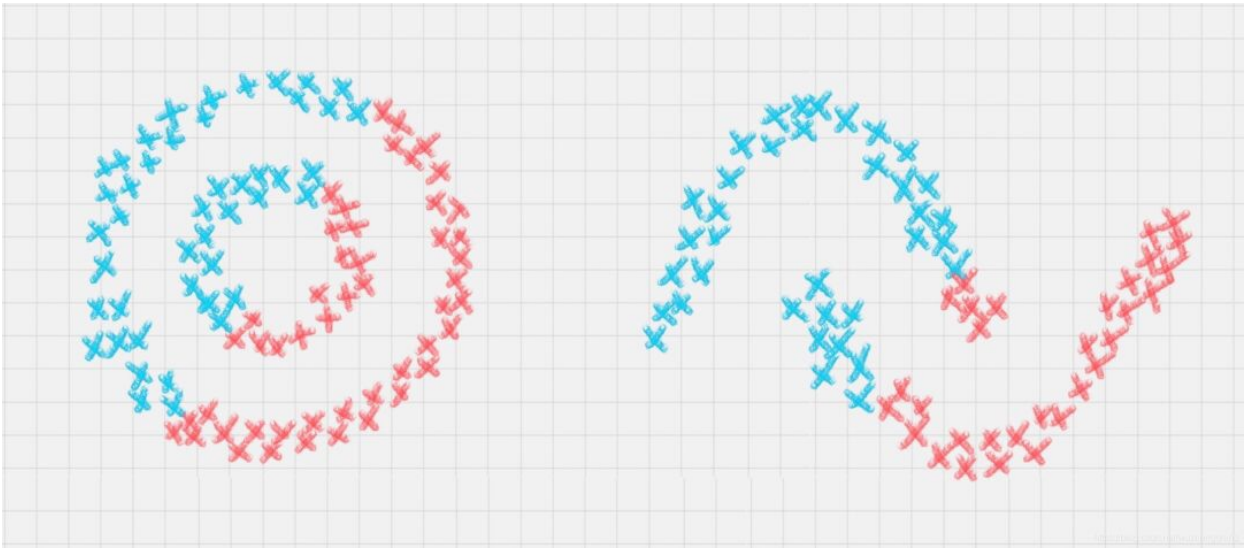

因为 K-Means 是通过距离来区分样本之间的差别的，且每个样本在计算的时候只能属于一个分类，称之为是硬聚类算法。而 EM 聚类在求解的过程中，实际上每个样本都有一定的概率和每个聚类相关，叫做软聚类算法。

> ★
>
> 你可以把 EM 算法理解成为是一个框架，在这个框架中可以采用不同的模型来用 EM 进行求解。常用的 EM 聚类有 GMM 高斯混合模型和 HMM 隐马尔科夫模型。GMM（高斯混合模型）聚类就是 EM 聚类的一种。比如上面这两个图，可以采用 GMM 来进行聚类。
>
> ”

和 K-Means 一样，我们事先知道聚类的个数，但是不知道每个样本分别属于哪一类。通常，我们可以假设样本是符合高斯分布的（也就是正态分布）。每个高斯分布都属于这个模型的组成部分（component），要分成 K 类就相当于是 K 个组成部分。这样我们可以先初始化每个组成部分的高斯分布的参数，然后再看来每个样本是属于哪个组成部分。这也就是 E 步骤。

再通过得到的这些隐含变量结果，反过来求每个组成部分高斯分布的参数，即 M 步骤。反复 EM 步骤，直到每个组成部分的高斯分布参数不变为止。

这样也就相当于将样本按照 GMM 模型进行了 EM 聚类。

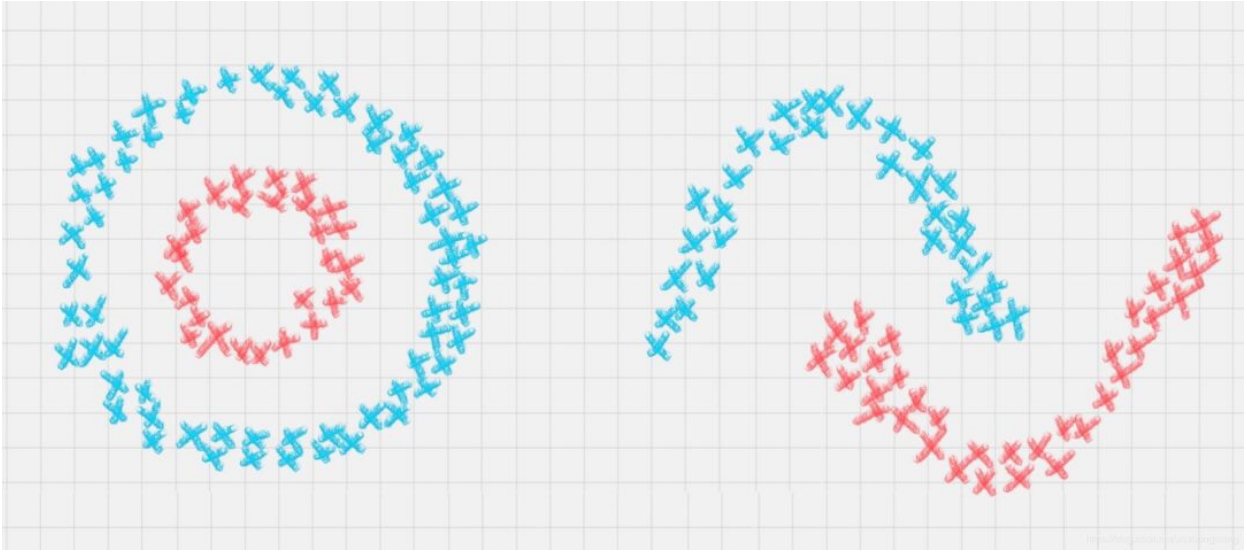

所以说很多KMeans解决不了的问题，EM聚类是可以解决的。在 EM 框架中，我们将潜在类别当做隐藏变量，样本看做观察值，把聚类问题转化为参数估计问题，最终把样本进行聚类。

最后再多啰嗦一句，EM 算法相当于一个框架，你可以采用不同的模型来进行聚类，比如 GMM（高斯混合模型），或者 HMM（隐马尔科夫模型）来进行聚类。

- GMM 是通过概率密度来进行聚类，聚成的类符合高斯分布（正态分布）。
- 而 HMM 用到了马尔可夫过程，在这个过程中，我们通过状态转移矩阵来计算状态转移的概率。HMM 在自然语言处理和语音识别领域中有广泛的应用。

好了，也说了EM算法聚类的原理了，下面让我们实战吧！

5. EM算法实战 - 王者荣耀英雄的聚类

上面是EM算法的原理，懂了原理之后，趁热打铁，做一个实际的小项目，看看EM算法的威力吧！

5.1 如何使用EM工具包

在 Python 中有第三方的 EM 算法工具包。由于 EM 算法是一个聚类框架，所以你需要明确你要用的具体算法，比如是采用 GMM 高斯混合模型，还是 HMM 隐马尔科夫模型。

我们主要是用GMM，所以需要引入工具包

```
from sklearn.mixture import GaussianMixture
```

那么如何创建GMM聚类呢？

gmm = GaussianMixture(n_components=1, covariance_type='full', max_iter=100)来创建， 参数如下：

- n_components：即高斯混合模型的个数，也就是我们要聚类的个数，默认值为 1。如果你不指定 n_components，最终的聚类结果都会为同一个值。
- covariance_type：代表协方差类型。一个高斯混合模型的分布是由均值向量和协方差矩阵决定的，所以协方差的类型也代表了不同的高斯混合模型的特征。协方差类型有 4 种取值：

- covariance_type=full，代表完全协方差，也就是元素都不为 0；
- covariance_type=tied，代表相同的完全协方差；
- covariance_type=diag，代表对角协方差，也就是对角不为 0，其余为 0；
- covariance_type=spherical，代表球面协方差，非对角为 0，对角完全相同，呈现球面的特性。

"

- max_iter：代表最大迭代次数，EM 算法是由 E 步和 M 步迭代求得最终的模型参数，这里可以指定最大迭代次数，默认值为 100。

"

创建完GMM聚类器之后，可以传入数据让它进行迭代拟合。
我们使用 fit 函数，传入样本特征矩阵，模型会自动生成聚类器，然后使用 prediction=gmm.predict(data) 来对数据进行聚类，传入你想进行聚类的数据，可以得到聚类结果 prediction。

你能看出来拟合训练和预测可以传入相同的特征矩阵，这是因为聚类是无监督学习，你不需要事先指定聚类的结果，也无法基于先验的结果经验来进行学习。只要在训练过程中传入特征值矩阵，机器就会按照特征值矩阵生成聚类器，然后就可以使用这个聚类器进行聚类了。

5.2如何用 EM 算法对王者荣耀数据进行聚类

首先我们知道聚类的原理是“人以群分，物以类聚”。通过聚类算法把特征值相近的数据归为一类，不同类之间的差异较大，这样就可以对原始数据进行降维。通过分成几个组（簇），来研究每个组之间的特性。或者我们也可以把组（簇）的数量适当提升，这样就可以找到可以互相替换的英雄，比如你的对手选择了你擅长的英雄之后，你可以选择另一个英雄作为备选。

5.2.1 数据集的介绍

看看数据的样子：数据集在这里下载

英雄	最大生命	生命成长	初始生命	最大法力	法力成长	初始法力	最高物攻	物攻成长	初始物攻	最大物防	物防成长	初始物防	最大每5秒	每5秒回血	初始每5秒	最大每5秒	每5秒回蓝	初始每5秒	最大攻速	攻击范围	主要定位
夏侯惇	7350	288.8	3307	1746	94	430	321	11.57	159	397	21.14	101	98	3.357	51	37	1.571	15	28.00%	近战	坦克
钟无艳	7000	275	3150	1760	95	430	318	11	164	409	22.07	100	92	3.143	48	37	1.571	15	14.00%	近战	战士
张飞	8341	329.4	3450	100	0	100	301	10.57	153	504	27.07	125	115	4.143	57	5	0	5	14.00%	近战	坦克
牛魔	8476	352.8	3537	1926	104	470	273	8.357	156	394	20.36	109	117	4.214	58	42	1.786	17	14.00%	近战	坦克
吕布	7344	270	3564	0	0	0	343	12.36	170	390	20.79	99	97	3.071	54	0	0	0	14.00%	近战	战士
亚瑟	8050	316.3	3622	0	0	0	346	13	164	400	21.57	98	106	3.643	55	0	0	0	14.00%	近战	战士
半月	6164	281.5	3105	100	0	100	289	9.786	152	361	19.5	88	77	2.357	44	0	0	0	0.00%	远程	法师
程咬金	8611	369.6	3437	0	0	0	316	11.07	161	504	27.07	125	119	4.429	57	0	0	0	28.00%	近战	坦克
廉颇	9328	412.1	3558	1708	92	420	286	8.786	163	514	27.29	132	128	4.929	59	36	1.5	15	14.00%	近战	坦克
东皇太一	7669	319.1	3201	1926	104	470	286	8.786	163	360	18.64	99	106	3.786	53	42	1.786	17	14.00%	近战	坦克
庄周	8149	345.6	3311	1694	91	420	297	9.071	170	497	24.79	150	113	4.143	55	36	1.5	15	14.00%	近战	辅助
太乙真人	6835	242.3	3443	1680	90	420	284	9.286	154	396	21.57	94	86	2.643	49	35	1.429	15	14.00%	近战	辅助
白起	8638	366.3	3510	1666	89	420	288	9.286	158	430	22.14	120	119	4.357	58	34	1.429	14	14.00%	近战	坦克
雅典娜	6264	243	2862	1732	93	430	327	11.79	162	418	22.29	106	83	2.786	44	36	1.5	15	28.00%	近战	战士
刘邦	8073	336	3369	1940	105	470	302	10.29	158	504	27.07	125	117	4.214	58	42	1.786	17	42.00%	近战	坦克
刘禅	8581	372.6	3364	1694	91	420	295	8.357	178	459	22.86	139	118	4.429	56	36	1.5	15	14.00%	近战	坦克
墨子	7176	292.4	3083	1722	93	420	328	10.5	181	475	26.64	102	100	3.5	51	37	1.571	15	28.00%	近战	法师
项羽	8057	380.1	3535	1694	91	420	306	10.64	157	494	26.5	123	121	4.5	58	36	1.5	15	14.00%	近战	坦克
关羽	7107	270.4	3322	10	0	10	343	12.36	170	386	20.36	101	94	3.071	51	0	0	0	7.00%	近战	战士

这里我们收集了 69 名英雄的 20 个特征属性，这些属性分别是最大生命、生命成长、初始生命、最大法力、法力成长、初始法力、最高物攻、物攻成长、初始物攻、最大物防、物防成长、初始物防、最大每 5 秒回血、每 5 秒回血成长、初始每 5 秒回血、最大每 5 秒回蓝、每 5 秒回蓝成长、初始每 5 秒回蓝、最大攻速和攻击范围等。

5.2.2执行流程

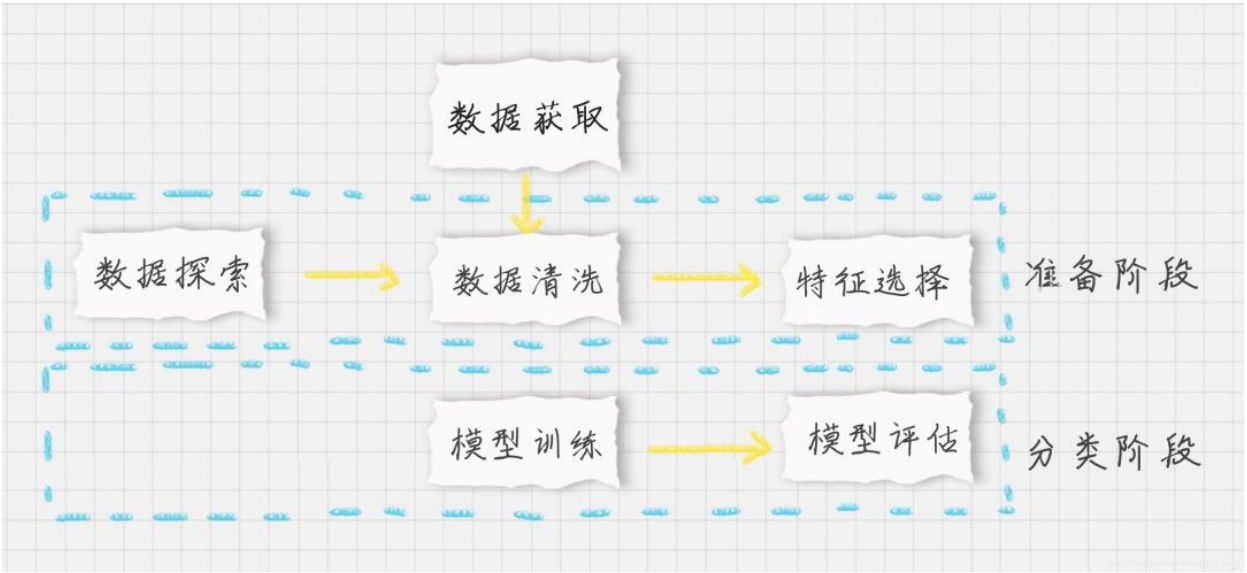

1. 首先加载数据源

2. 在准备阶段，我们需要对数据进行探索，包括采用数据可视化技术，让我们对英雄属性以及这些属性之间的关系理解更加深刻，然后对数据质量进行评估，是否进行数据清洗，最后进行特征选择方便后续的聚类算法

3. 聚类阶段：选择适合的聚类模型，这里我们采用 GMM 高斯混合模型进行聚类，并输出聚类结果，对结果进行分析。

5.2.3 实战操作

1. 首先导入包

```
import pandas as pd
import csv
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.preprocessing import StandardScaler
from sklearn.mixture import GaussianMixture
```

1. 加载数据

```
# 数据加载，避免中文乱码问题
data_ori = pd.read_csv('dataset/heros.csv', encoding = 'gb18030')
features = [u'最大生命',u'生命成长',u'初始生命',u'最大法力', u'法力成长',u'初始法力',u'最高物攻',u'物攻成长',u'初始物攻',u'最大物防',u'物防成长',u'初始物防', u'最大每5秒回血', u'每5秒回血成长', u'初始每5秒回血', u'最大每5秒回蓝', u'每5秒回蓝成长', u'初始每5秒回蓝', u'最大攻速', u'攻击范围']
data = data_ori[features]
```

1. 数据可视化的探索 我们将 20 个英雄属性之间的关系用热力图呈现了出来，中间的数字代表两个属性之间的关系系数，最大值为 1，代表完全正相关，关系系数越大代表相关性越大。从图中你能看出来“最大生命” “生命成长”和“初始生命”这三个属性的相关性大，我们只需要保留一个属性即可。同理我们也可以对其他相关性大的属性进行筛选，保留一个。你在代码中可以看到，我用 features_remain 数组保留了特征选择的属性，这样就将原本的 20 个属性降维到了 13 个属性。

```
 # 对英雄属性之间的关系进行可视化分析
# 设置plt正确显示中文
plt.rcParams['font.sans-serif']=['SimHei'] #用来正常显示中文标签
plt.rcParams['axes.unicode_minus']=False #用来正常显示负号
# 用热力图呈现features_mean字段之间的相关性
corr = data[features].corr()
plt.figure(figsize=(14,14))
# annot=True显示每个方格的数据
```

```
sns.heatmap(corr, annot=True)
plt.show()
```

结果如下：

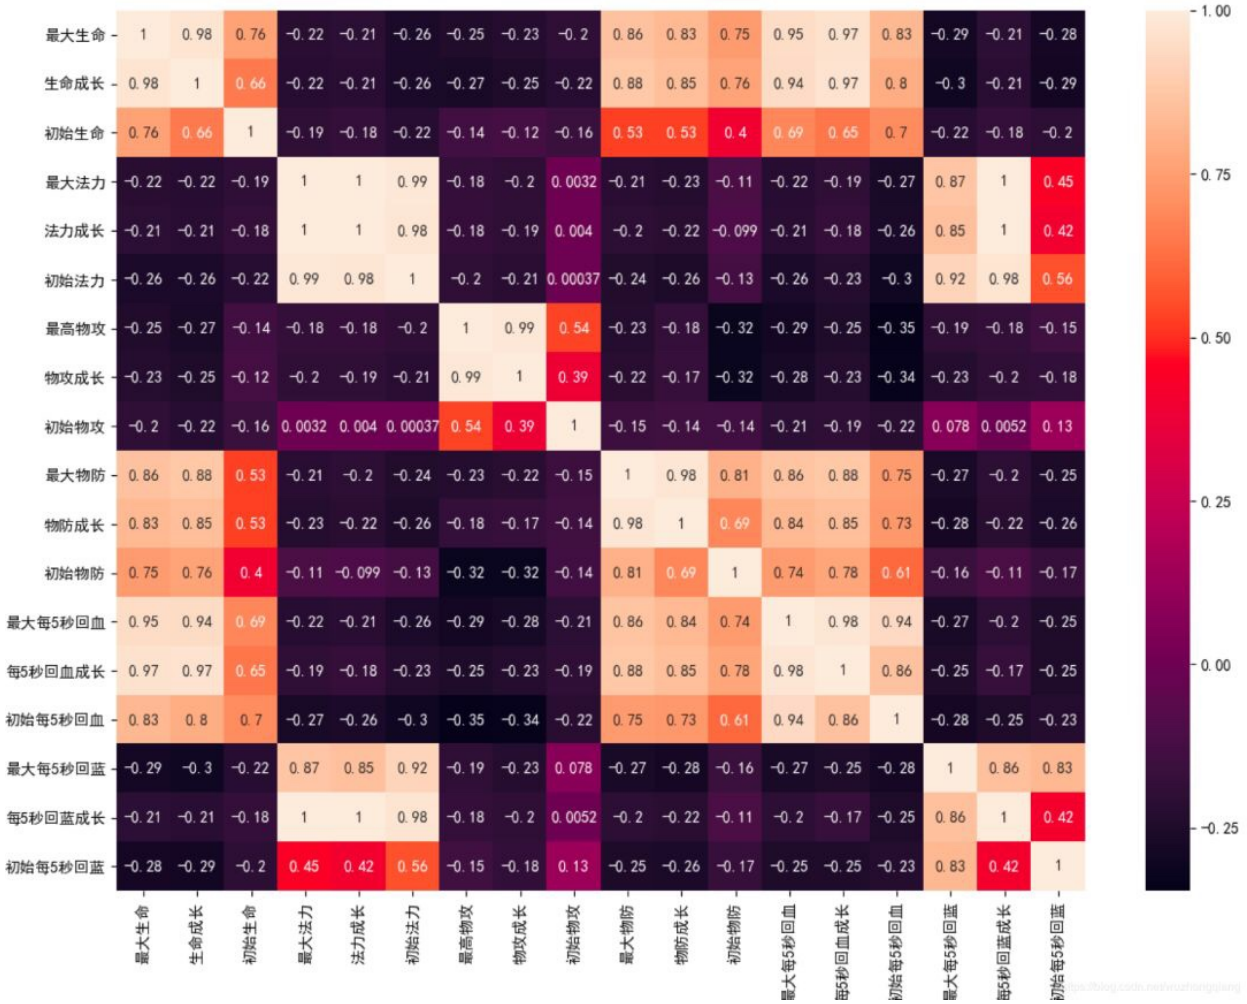

1. 特征工程

```
# 相关性大的属性保留一个，因此可以对属性进行降维
features_remain = [u'最大生命', u'初始生命', u'最大法力', u'最高物攻', u'初始物攻', u'最大物防', u'初始物防', u'最大每5秒回血', u'最大每5秒回蓝', u'初始每5秒回蓝', u'最大攻速', u'攻击范围']
data = data_ori[features_remain]
```

1. 数据规范化 我们能看到“最大攻速”这个属性值是百分数，不适合做矩阵运算，因此我们需要将百分数转化为小数。我们也看到“攻击范围”这个字段的取值为远程或者近战，也不适合矩阵运算，我们将取值做个映射，用 1 代表远程，0 代表近战。然后采用 Z-Score 规范化，对特征矩阵进行规范化。

```
data[u'最大攻速'] = data[u'最大攻速'].apply(lambda x: float(x.strip('%'))/100)
data[u'攻击范围']=data[u'攻击范围'].map({'远程':1,'近战':0})

# 采用Z-Score规范化数据，保证每个特征维度的数据均值为0，方差为1
ss = StandardScaler()
data = ss.fit_transform(data)
```

1. 建模并产生结果，写入文件

```
# 构造GMM聚类
gmm = GaussianMixture(n_components=30, covariance_type='full')
gmm.fit(data)
# 训练数据
prediction = gmm.predict(data)
print(prediction)
# 将分组结果输出到CSV文件中
data_ori.insert(0, '分组', prediction)


# 结果如下:

[28 14  8  9  5  5 15  8  3 14 18 14  9  7 16 18 13  3  5  4 19 12  4 12
 12 12  4 17 24  2  7  2  2 24  2  2 24  6 20 22 22 24 24  2  2 22 14 20
 14 24 26 29 27 25 25 28 11  1 23  5 11  0 10 28 21 29 29 29 17]
```

我们采用了 GMM 高斯混合模型，并将结果输出到 CSV 文件中。这里我将输出的结果截取了一段（设置聚类个数为 30）：

8	张飞	8341	329.4	3450	100	0
8	程咬金	8611	369.6	3437	0	0
9	牛魔	8476	352.8	3537	1926	104
9	白起	8638	366.3	3510	1666	89
10	老夫子	7155	270.4	3370	5	0
11	达摩	7140	280.5	3213	1694	91
11	典韦	7516	291.6	3434	1774	96

第一列代表的是分组（簇），我们能看到张飞、程咬金分到了一组，牛魔、白起是一组，老夫子自己是一组，达摩、典韦是一组。聚类的特点是相同类别之间的属性值相近，不同类别的属性值差异大。因此如果你擅长用典韦这个英雄，不防试试达摩这个英雄。同样你也可以在张飞和程咬金中进行切换。这样就算你的英雄被别人选中了，你依然可以有备选的英雄可以使用。

聚类和分类不一样，聚类是无监督的学习方式，也就是我们没有实际的结果可以进行比对，所以聚类的结果评估不像分类准确率一样直观，那么有没有聚类结果的评估方式呢？这里我们可以采用 Calinski-Harabaz 指标，代码如下：

```
from sklearn.metrics import calinski_harabaz_score
print(calinski_harabaz_score(data, prediction))
```

指标分数越高，代表聚类效果越好，也就是相同类中的差异性小，不同类之间的差异性大。当然具体聚类的结果含义，我们需要人工来分析，也就是当这些数据被分成不

同的类别之后，具体每个类表代表的含义。

另外聚类算法也可以作为其他数据挖掘算法的预处理阶段，这样我们就可以将数据进行降维了。

6. 总结

到这终于写完了， 我的天啊，每次写都是这么多，这可以慢慢的干货啊，虽然多，但真的可以学到东西。 赶紧来总结一下，今天首先从分菜的例子出发，感受了一下EM算法。

然后，我们从抛硬币的例子，知道了初级EM和升级版EM。然后解释了EM的工作原理，EM 算法中的 E 步骤就是通过旧的参数来计算隐藏变量。然后在 M 步骤中，通过得到的隐藏变量的结果来重新估计参数。直到参数不再发生变化，得到我们想要的结果。

接下来，就是对比了EM和KMeans的区别，知道了EM可以解决Kmeans不能解决的一些问题，并且EM是个框架，具体实现包括高斯混合模型和隐马尔可夫模型，后期会具体讲隐马尔可夫。

最后，调用sklearn的EM算法工具完成了一个王者荣耀英雄的聚类任务， 知道了一个衡量聚类结果的函数。

希望通过今天的学习可以对EM算法在感性上有一个了解，至于理性方面， 可以看看西瓜书或者统计学习方法进行深一步的学习了。

参考:

- http://note.youdao.com/noteshare?id=2949a4c56e27b97df5fa282dc75060e7&sub=B08633D2250849F2B33A5947351E8389
- https://www.cnblogs.com/coshaho/p/9573367.html
- https://blog.csdn.net/taka_is_beauty/article/details/88095032